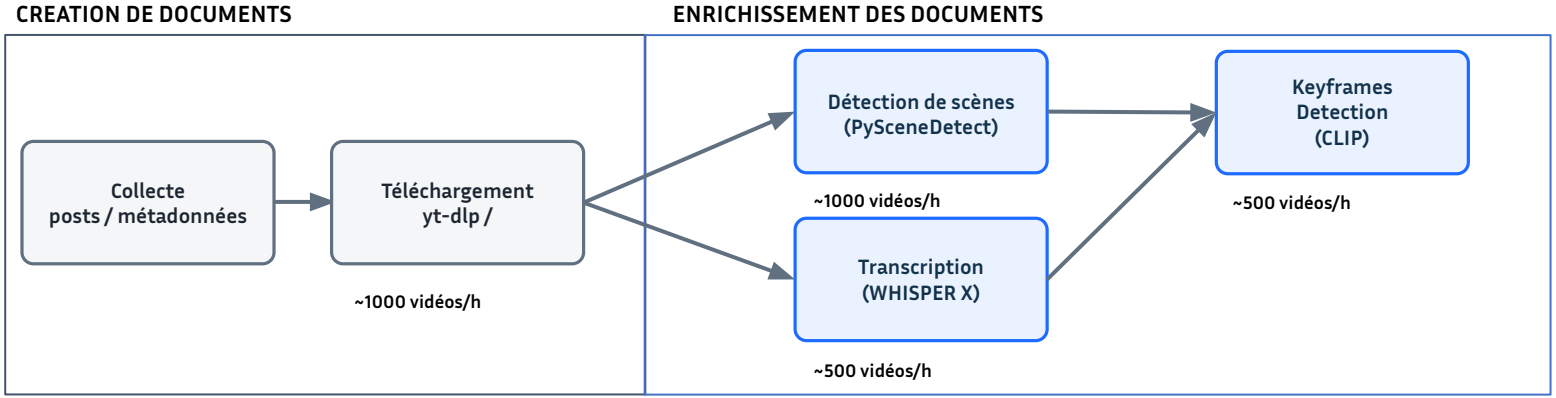
Video Mining

Pipeline technique, cas d’usage analytiques et prochaines étapes

opsci

Pipeline Video Mining cible

Chaque étape transforme un média brut en signaux structurés utilisables par les use cases.





Narrative analysis

A partir des transcripts, on peut détecter des narratifs

Topic modeling (transcripts)

On peut aussi modéliser les sujets



Classification des scènes

A partir des images signature, on peut classer les scènes (topic modeling)



Circulation & reprises de scènes

On peut analyser la circulation des scènes entre vidéos (coordination)

Capacités de collecte et téléchargement vidéo par plateforme

Périmètre : vidéos uniquement. Selon la plateforme, la vidéo peut être téléchargeable plus tard, devoir être téléchargée immédiatement, ou être indisponible sans re-scraping.

YouTube
CF youtube-video-downloader

- Téléchargement possible plus tard après la collecte
- Performance connue : ~25 vidéos / 15 min / instance CPU
- Capacité estimée : 1 000 vidéos / 1h avec 10 instances CPU

TikTok, Telegram, Linkedin, Threads
CF documents-downloader

- Téléchargement des images au moment de la collecte (ou nécessite de recollecter les posts pour récupérer la vidéo) car les URLs sont temporaires / signées
- Vidéos téléchargeables via appel HTTP simple
- **TO DO : implémenter le scénario de collecte par ID de posts pour TikTok, Linkedin, Threads**

URLs stables
X · Bluesky · Presse

- Vidéos disponibles via URLs stables
- Téléchargeable à tout moment après collecte avec documents-downloader en HTTP
- **Performance connue : ~25 vidéos / 15 min / instance CPU**

Truth Social · Reddit

- Truth Social : MP4 bloqués actuellement par Cloudflare (une utilisation de OVH vps pourra être explorée)
- Reddit : vidéos v.redd.it non stockées par le scraper. Pas de pipeline pour télécharger les liens partagés (ex youtube)

Use case 1 — Reprises de scènes (coordination)

Objectif : retrouver des scènes ou séquences de scènes reprises dans d'autres vidéos, même après recadrage, compression, filtre ou recontextualisation.

Intérêt Métier : détecter la circulation et l'amplification coordonnées de séquences vidéo entre acteurs afin d'identifier des campagnes d'influence, des relais de désinformation et des reprises opportunistes entre communautés.

Pipeline :



1 — Indexer les scènes

· Chaque scène est représentée par ses keyframes

· Les keyframes sont encodées avec **CLIP ViT-B-32** / OpenAI

· L'embedding de scène est la moyenne des embeddings des keyframes

· Le vecteur est normalisé L2 pour permettre la comparaison cosinus

2 — Comparer les scènes

· Calcul matriciel des similarités cosinus entre toutes les scènes

· **Seuil PoC : 0,97** pour détecter les quasi-reprises

· Matching 1–1 par paire de vidéos

· Les meilleurs appariements sont conservés par ordre de similarité

3 — Construire les reprises

· Les scènes appariées sont étendues en séquences consécutives maximales

· Les séquences proches sont regroupées en ensembles connectés

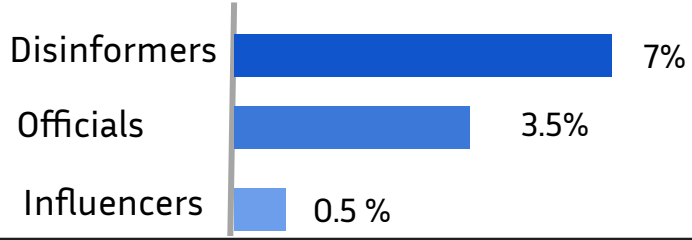
· Un graphe dirigé de reprise est construit entre occurrences

· Chaque lien conserve similarité, longueur de séquence et caractère exact ou partiel

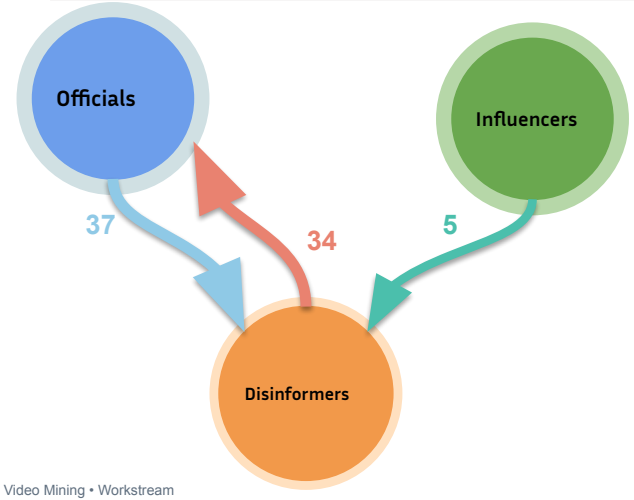
Use case 1 — Reprise de scènes entre vidéos : Romania Imuna

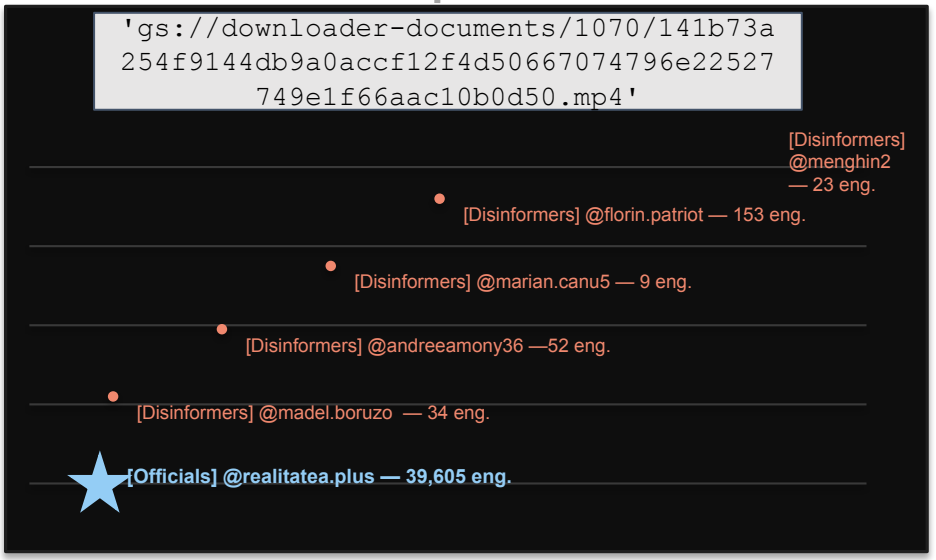
- **Dataset** : collecte de **14K** vidéos Tiktok,, à partir de nos panels Romania Imuna:
  - Disinformers: **8 809 vidéos sur 482 comptes**
  - Influencers: **2 828 vidéos** sur **260** comptes
  - Officials: **2 728 vidéos sur 182 comptes**
- **402 séquences** ont été identifiées comme reprises au sein de **700 vidéos (5 % du dataset)**. **296 vidéos** reprises dans leur intégralité..
- **147 comptes sur 924 sont impliqués dans des reprises de scènes. Ils se structurent en 13 communautés, dont la plus importante regroupe 115 comptes, parmi lesquels 98 sont des désinformateurs.**

% Vidéos impliquées dans les reprises



Reprises de séquences entre acteurs



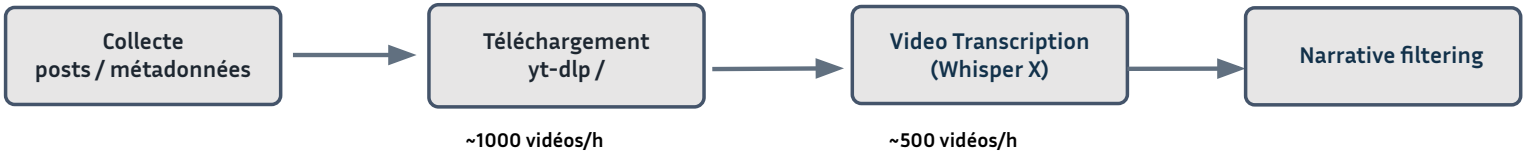


Use case 2 — Narrative analysis sur transcripts

Objectif : Détecter automatiquement quels narratifs de désinformation sont présents dans les transcriptions de vidéos, en mesurant la similarité sémantique entre chaque segment de discours et une ensemble de claims pré-définis

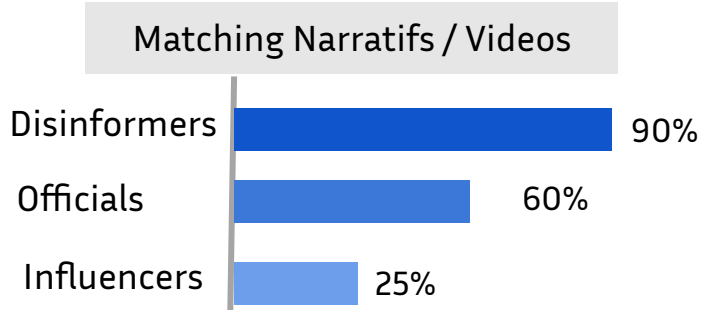
Intérêt Métier : La vidéo est le format dominant de la désinformation contemporaine, mais elle reste opaque à l'analyse de contenu à grande échelle. En ouvrant la transcription comme surface d'analyse narrative, ce use case permet de **traiter des plateforme comme YouTube et TikTok avec la même rigueur que le texte écrit**, et d'intégrer ces plateformes dans un dispositif de veille unifié. Les analystes disposent alors d'une lecture structurée de l'espace narratif : quels récits circulent, portés par quels types d'acteurs, qui les initie en premier et comment ils se propagent.

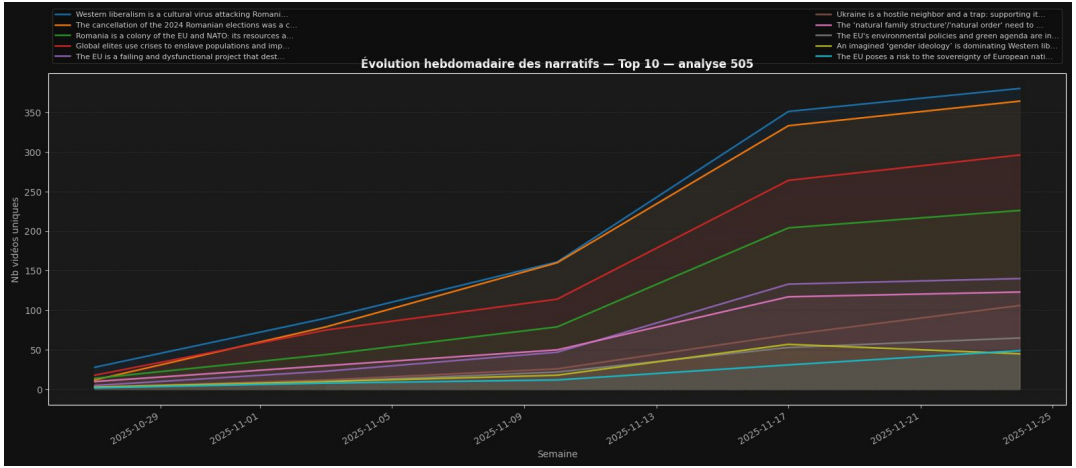
Pipeline :

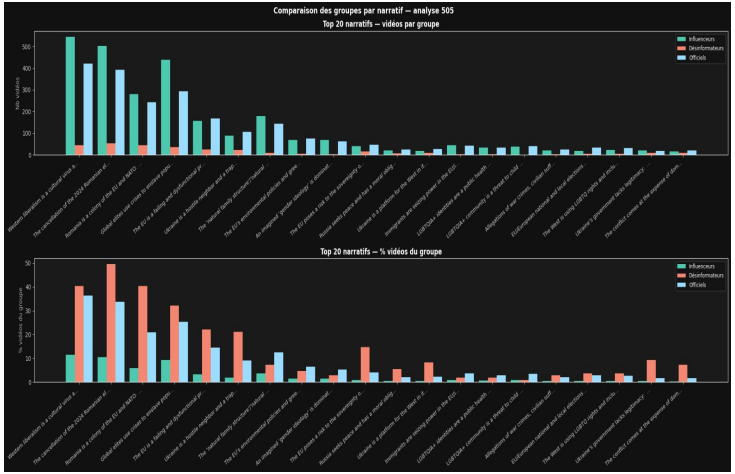


Use case 2 — Narrative analysis sur transcripts vidéo : Romania Imuna

- **Dataset** : collecte de **6K** vidéos Youtube, à partir de nos panels Romania Imuna:
  - Disinformers: **109 vidéos sur 13 comptes**
  - Influencers: **4 786 vidéos** sur **247** comptes
  - Officials: **1 162 vidéos sur 76 comptes**
- **2 080 vidéos**, soit **35 %** du dataset, correspondent chacune à au moins un narratif. Chez les désinformateurs, 9 vidéos sur 10 sont liées à au moins un narratif ; cette proportion chute à 1 sur 4 chez les influenceurs.
- **28 narratifs** ont été identifiés. On détecte **5x plus de narratifs de désinformation qu'en analysant les titres / descriptions de vidéo**







Politique roumaine & *corruption interne*

9 NARRATIFS

N01
Politiciens roumains mentent sans honte, brisent leurs promesses électorales et changent de camp pour leur gain personnel, et aucun n'est jamais condamné pour fraude politique.

N02
La classe politique a corrompu chaque institution roumaine depuis 1989 en imposant des décisions incompétentes et en transformant justice et sécurité en instruments de ses propres intérêts.

N03
Les magistrats roumains forment une caste privilégiée liée aux services secrets et aux élites politiques, qui s'accroche à des pensions injustifiées et se protège elle-même au détriment des citoyens.

N04
Les conseils départementaux servent des intérêts politiques au mépris des citoyens et seule la mobilisation civique peut les contraindre à rendre des comptes.

N05
Les élites roumaines protègent jalousement leurs privilèges et ignorent les quartiers pauvres de Bucarest, tandis que le peuple paie le prix de leur cupidité.

N06
La politique roumaine est gangrenée par une **mafia transpartisane** qui pille les budgets, protège ses intérêts immobiliers et trahit les citoyens sous couvert d'opposition factice.

N07
Les institutions constitutionnelles restent silencieuses face aux attaques contre la magistrature, révélant leur soumission à une élite corrompue qui méprise transparence et démocratie.

N08
Les gouvernants roumains forment une caste corrompue qui impose l'austérité au peuple tout en épargnant politiciens, magistrats et clientèles, trahissant la démocratie.

N09
Le gouvernement Bolojan sacrifie les Roumains par des coupes injustes et finance l'Ukraine au lieu de protéger les consommateurs et de réformer véritablement le pays.

Géopolitique & *influence étrangère*

8 NARRATIFS

N10
Donald Trump dirige les États-Unis comme un marchand capricieux et narcissique, obligeant les alliés à flatter son ego au lieu de bâtir des relations stables, ce qui affaiblit l'Occident.

N11
L'administration Trump abandonne l'Europe et se laisse manipuler par Poutine et Xi Jinping, ses émissaires comme **Witkoff** travaillant en réalité pour les intérêts russes.

N12
Poutine et la Russie prospèrent dans la guerre et menacent l'Europe, tandis que les politiciens compradores liés au Kremlin trahissent leurs pays au profit de Moscou.

N13
Sans la protection américaine et l'Europe, **l'Ukraine** et les démocraties de l'Est seraient livrées à l'agression russe, ce qui rend toute complaisance envers Poutine une trahison de la sécurité collective.

N14
La Russie orchestre des campagnes de propagande et de dénigrement contre la Moldavie pour empêcher son intégration européenne et la maintenir sous son influence.

N15
Les habitants de **Gagaouzie** aux multiples passeports restent loyaux à Poutine et trahissent les intérêts de la Moldavie au profit du Kremlin.

N16
L'Europe est une puissance déclinante et divisée, infiltrée par des agents étrangers et dépendante de l'Amérique, incapable de défendre ses intérêts face à la Russie, la Chine et les États-Unis.

N17
Ceaușescu a bâti un système de répression qui haïssait son propre peuple, et la nostalgie communiste ressurgit aujourd'hui sous l'influence de campagnes de désinformation russes.

Société, idéologie, *ordre social*

7 NARRATIFS

N18
L'homme doit reprendre son rôle naturel de protecteur, pourvoyeur et chef de famille, sinon la société produit des hommes efféminés et des femmes malheureuses.

N19
L'indépendance financière des femmes a détruit l'idée de famille et rendu les hommes superflus, ce qui explique la crise actuelle des rôles de genre.

N20
Les antivaccinistes et les propagateurs de fausses informations mettent en danger la société en sapant la confiance dans les vaccins éprouvés et la médecine scientifique.

N21
La Roumanie étouffe les investisseurs par sa bureaucratie absurde et son imprévisibilité fiscale, pendant que **Dubaï** offre la certitude et la prospérité que nos dirigeants ne savent pas garantir.

N22
George Simeon et l'AUR incitent à la violence politique en publiant des listes de cibles et en manipulant l'argent public, tout en bénéficiant d'une impunité scandaleuse face aux autorités.

N23
La police réprime brutalement les manifestants pacifiques pendant que les agitateurs politiques proches du pouvoir agissent en toute liberté, justice à deux vitesses au service du régime.

N24
Les russophones et certains parlementaires méprisent la langue roumaine et refusent de s'intégrer, trahissant le pays qui les accueille pendant que les élites tardent à défendre l'identité nationale.

Spiritualité & *relations intimes*

4 NARRATIFS

N25
Les relations toxiques sont le fruit du péché qui a infecté l'humanité, seul le retour au modèle biblique des relations voulues par Dieu peut restaurer des liens sains.

N26
Opérer avec **des demi-vérités** et embellir la réalité dans le couple est un mécanisme manipulateur qui détruit la confiance et active l'insécurité du partenaire.

N27
Les fidèles se tournent vers l'horoscope, la magie et les sorciers au lieu de l'Église, signe d'une société spirituellement perdue que seul le retour à la foi orthodoxe peut sauver.

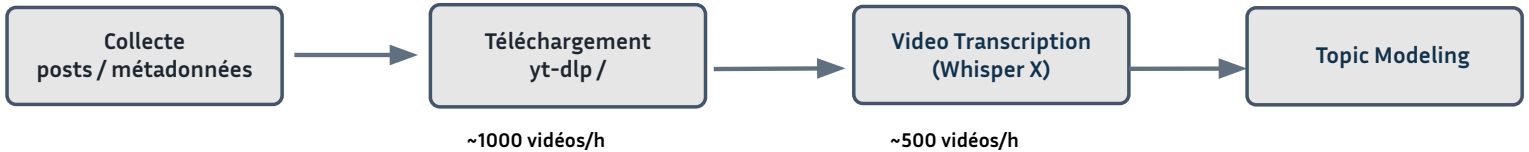
N28
L'Église a été détournée par les évêques de Rome qui se sont autoproclamés vicaires du Christ et ont corrompu la vraie tradition chrétienne.

Use case 3 — Topic modeling sur les transcripts

Objectif : Étendre le pipeline de topic modeling existant aux transcriptions de vidéos, pour identifier automatiquement les grandes thématiques qui circulent dans un corpus vidéo.

Intérêt Métier : Le topic modeling tourne déjà sur nos données texte. Mais une part croissante du discours public ne s'écrit plus — elle se filme. En branchant le même pipeline sur les transcriptions video, on cesse d'ignorer ce que disent les créateurs de contenu. Un sujet peut monter en puissance sur TikTok plusieurs jours avant d'apparaître dans les posts texte ; sans analyse vidéo, cette fenêtre est invisible. Ce use case permet aux analystes de travailler sur un corpus vraiment complet, de comparer les dynamiques thématiques entre plateformes, et de repérer là où l'agenda se forme avant qu'il ne se propage.

Pipeline :



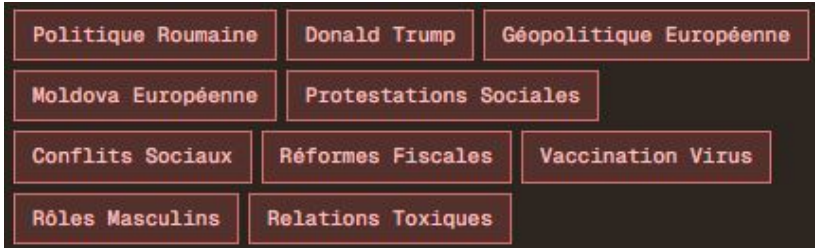
Use case 3 — Topic modeling sur les transcripts : Romania Imuna

Les titres / descriptions de vidéo montrent une vitrine neutre, optimisée pour le SEO. L'analyse des transcripts révèle un discours chargé, politique et conflictuel. Sur un corpus de 2000 vidéo, **on détecte 2.5x plus de topics, 5x plus de narratifs de désinformation et des contenus 6x plus négatifs.**

Les titres révèlent des clusters mono-thématiques, neutres et descriptifs, tandis que les transcripts sont associés à une diversité plus importante de sujets : l'orateur aborde plusieurs sujets au cours de la vidéo.



VS



Use case 4 — Topic Visual Mining sur les keyframes

Objectif : Détecter les assets visuels récurrents dans un corpus vidéo en regroupant les keyframes par similarité, pour révéler les familles de contenus visuellement liés indépendamment de leur discours.

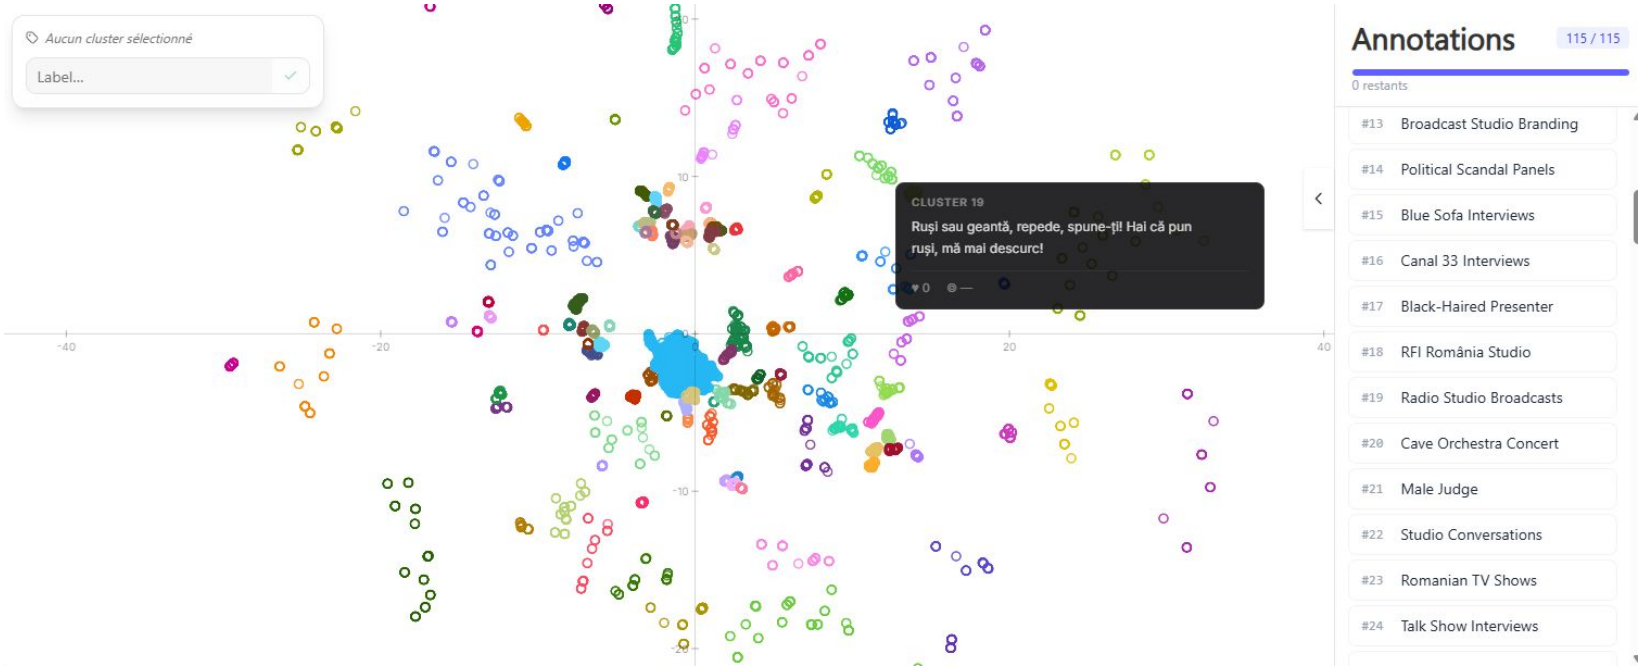
Intérêt Métier : La désinformation coordonnée laisse des empreintes visuelles que le texte ne détecte pas. Un même fond, un même graphique, une même séquence peuvent traverser des centaines de vidéos publiées par des comptes distincts, signe d'une production centralisée ou d'un kit de contenu partagé. En clusterisant les keyframes, on expose ces connexions invisibles : deux vidéos au discours différent mais au visuel identique révèlent une coordination que l'analyse textuelle aurait manquée.

Pipeline :



Use case 4 — Topic Visual Mining sur les keyframes : Romania Imuna

- **Dataset** : **2000** vidéos Youtube , à partir de nos panels Romania Imuna - Les Officials
- **200K** keyframes sélectionnés



Synthèse & arbitrage

Le pipeline dispose déjà de briques solides ; la valeur se matérialise via 4 use cases analytiques.

- Un socle technique GCP capable de produire scènes, transcripts, chunks, keyframes et embeddings.
- TO DO :
  - refactoring sur la brique de Network Graph
- Complémentarité démontrée avec nos pipelines existants (Narrative filtering, reprises de scène...)
- Arbitrages:
  - Intérêt pour les usecases présentés ?
  - Identifier a minima un cas d'application pour rôder notre pipeline ?
  - Réflexion produit associé (interfaces ? intégration Spine ? ...)